



เรื่อง การวินิจฉัยเชิงพยากรณ์สำหรับภาวะโรคหัวใจระยะเริ่มต้นโดยใช้แมชชีนเลิร์นนิง

Predictive Diagnosis of Early-Stage Heart Conditions using Machine Learning

จัดทำโดย

1. 6630251059 นายจิรายุ ชูเนตร,
2. 6630251229 นายวิษุทธิ์ วิฐชัย
3. 6630251237 นางสาวศศิธร แสงเพชร
4. 6630251334 นางสาวนลินธรรณ์ โสภากิริยธรรม
5. 6630251423 นางสาวเสาวลักษณ์ ประภาศิริสุลี

สาขาวิทยาการและเทคโนโลยีดิจิทัล คณะวิทยาศาสตร์ ศรีราชา

เสนอ

ผู้ช่วยศาสตราจารย์ ดร.กัญญ์ณัฐ หอมทรัพย์

อาจารย์สาขาวิทยาการและเทคโนโลยีดิจิทัล คณะวิทยาศาสตร์ ศรีราชา

รายงานเล่มเป็นส่วนหนึ่งของวิชา 02739341-64 Introduction to Artificial Intelligence

ภาคเรียนที่ 1 ปีการศึกษา 2568

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา

คำนำ

รายงานฉบับนี้มีวัตถุประสงค์เพื่อศึกษาการวินิจฉัยโรคหัวใจโดยใช้ชุดข้อมูล Prediction Heart Disease Dataset ซึ่งเป็นข้อมูลตัวอย่างที่รวบรวมปัจจัยต่าง ๆ ที่อาจส่งผลต่อการเกิดโรคหัวใจ เช่น อายุ ความดันโลหิต ระดับคอเลสเตอรอล อัตราการเต้นของหัวใจ และปัจจัยทางสุขภาพอื่น ๆ โดยจะนำข้อมูลเหล่านี้มาวิเคราะห์ด้วยเทคนิคทาง Data Science และ Machine Learning เพื่อคาดการณ์โอกาสในการเกิดโรคหัวใจของบุคคล

ผู้จัดทำหวังว่ารายงานฉบับนี้จะช่วยให้ผู้อ่านเข้าใจถึงกระบวนการนำเทคโนโลยีการวิเคราะห์ข้อมูลมาประยุกต์ใช้ในทางการแพทย์ และตระหนักถึงความสำคัญของการใช้ข้อมูลเพื่อสนับสนุนการตัดสินใจในการดูแลสุขภาพในยุคดิจิทัล

คณะผู้จัดทำ

สารบัญ

เรื่อง	หน้า
บทนำ	ก
วัตถุประสงค์	ข
ปัญหา	ค
ประโยชน์ของโครงการ	ง
บทที่ 1 Data Collection & Preprocessing	1
Exploratory Data Analysis (EDA)	
Missing Value Handling (Imputation / Drop)	3
Outlier Detection & Handling	5
Encode Categorical & Scale Numerical Features	8
Data Splitting (Train/Test หรือ Train/Validation/Test)	10
บทที่ 2 Feature Selection	11
Correlation Analysis	
Model-based Feature Importance	13
Explainability Methods (SHAP, Mutual Information (MI))	15
Feature Pruning	17
บทที่ 3 Modeling	18
Train Models	
Model Validation & Bias-Variance Check	20
Hyperparameter Tuning (GridSearchCV, Random Search)	21
Cross-validation (K-Fold CV)	
บทที่ 4 Evaluation Metrics	22
Evaluate Performance	
Export Model (pickle, joblib)	24
บทที่ 5 Explainability	25
บทที่ 6 Deployment	26
สร้าง Web App ด้วย Streamlit	
ค่าเตือนและข้อจำกัด	

บทนำ

โรคหัวใจเป็นสาเหตุการเสียชีวิตอันดับต้น ๆ ของโลก การตรวจวินิจฉัยและคาดการณ์ความเสี่ยงตั้งแต่ระยะเริ่มต้นสามารถช่วยลดอัตราการเสียชีวิตและเพิ่มประสิทธิภาพในการรักษาได้ ปัจจุบันเทคโนโลยีทางด้านปัญญาประดิษฐ์ และ Machine Learning ได้เข้ามามีบทบาทสำคัญในการวิเคราะห์ข้อมูลทางการแพทย์ โดยเฉพาะอย่างยิ่งในงานทำนายโรคต่าง ๆ จากข้อมูลทางสุขภาพของผู้ป่วย

Machine Learning เป็นสาขาหนึ่งของปัญญาประดิษฐ์ที่มุ่งเน้นให้คอมพิวเตอร์สามารถเรียนรู้ จากข้อมูลโดยไม่จำเป็นต้องถูกสั่งการโดยตรง ด้วยการใช้แบบจำลองทางสถิติและอัลกอริทึม เช่น Logistic Regression, Decision Tree, Random Forest ซึ่งสามารถวิเคราะห์รูปแบบและความสัมพันธ์ระหว่างปัจจัยทางสุขภาพที่ส่งผลต่อการเกิดโรคหัวใจได้อย่างแม่นยำ นอกจากนี้ Machine Learning ยังสามารถปรับปรุงประสิทธิภาพของโมเดลได้อย่างต่อเนื่องเมื่อได้รับข้อมูลเพิ่มเติม ทำให้ผลการวินิจฉัยมีความน่าเชื่อถือมากขึ้น

รายงานฉบับนี้มุ่งเน้นการนำชุดข้อมูล Prediction Heart Disease Dataset ของ UCLrvin มาวิเคราะห์และสร้างแบบจำลองเพื่อวินิจฉัยและคาดการณ์ความเสี่ยงของการเกิดโรคหัวใจ โดยใช้เทคนิคทาง Machine Learning เพื่อให้ได้ผลลัพธ์ที่แม่นยำ เข้าใจง่าย และสามารถนำไปประยุกต์ใช้ในการแพทย์ได้ในอนาคต

วัตถุประสงค์

1. เพื่อศึกษาการนำเทคนิค Machine Learning มาประยุกต์ใช้ในการวิเคราะห์และวินิจฉัยโรคหัวใจจากข้อมูลสุขภาพของผู้ป่วย
2. เพื่อสร้างแบบจำลองการคาดการณ์โรคหัวใจโดยใช้ชุดข้อมูล Prediction Heart Disease Dataset
3. เพื่อเปรียบเทียบประสิทธิภาพของโมเดล Machine Learning หลายประเภท เช่น Logistic Regression, Decision Tree, Random Forest เพื่อหาวิธีที่ให้ความแม่นยำสูงสุด
4. เพื่อระบุปัจจัยสำคัญที่มีผลต่อความเสี่ยงของการเกิดโรคหัวใจ ผ่านการวิเคราะห์คุณลักษณะ (Feature Importance)
5. เพื่อแสดงแนวทางการประยุกต์ใช้ Machine Learning ในการสนับสนุนการตัดสินใจทางการแพทย์ และเป็นพื้นฐานในการพัฒนาระบบวินิจฉัยอัตโนมัติในอนาคต

ปัญหา

ในปัจจุบันการวินิจฉัยโรคหัวใจส่วนใหญ่ต้องอาศัยการตรวจโดยแพทย์ผู้เชี่ยวชาญและเครื่องมือทางการแพทย์ที่มีค่าใช้จ่ายสูง เช่น การตรวจคลื่นไฟฟ้าหัวใจ (ECG) หรือการตรวจเอกซเรย์หัวใจ ซึ่งอาจทำให้ผู้ป่วยบางรายไม่สามารถเข้าถึงการตรวจได้อย่างทั่วถึง นอกจากนี้ การวิเคราะห์ข้อมูลสุขภาพมักมีความซับซ้อน เนื่องจากมีหลายปัจจัยที่ส่งผลต่อการเกิดโรคหัวใจ เช่น อายุ ความดันโลหิต ระดับคอเลสเตอรอล พฤติกรรมการใช้ชีวิต และพันธุกรรม

การใช้เทคนิค Machine Learning เข้ามาช่วยในการวิเคราะห์และคาดการณ์โรคหัวใจ จึงเป็นแนวทางสำคัญที่สามารถลดภาระของบุคลากรทางการแพทย์และเพิ่มความรวดเร็วในการประเมินความเสี่ยงเบื้องต้น อย่างไรก็ตาม การพัฒนาโมเดลให้มีความแม่นยำสูง จำเป็นต้องผ่านกระบวนการสำคัญหลายขั้นตอน เช่น การเตรียมข้อมูล (Data Preprocessing), การเลือกคุณลักษณะ (Feature Selection), การสร้างแบบจำลอง (Modeling) และการประเมินผล (Evaluation) หากแต่ละขั้นตอนดำเนินการไม่เหมาะสม อาจทำให้ผลลัพธ์คลาดเคลื่อนได้

ดังนั้น รายงานฉบับนี้จึงจัดทำขึ้นเพื่อแก้ไขปัญหาดังกล่าว โดยมุ่งเน้นการสร้างแบบจำลองการคาดการณ์โรคหัวใจด้วยเทคนิค Machine Learning ที่มีประสิทธิภาพ และสามารถนำไปประยุกต์ใช้ในเชิงการแพทย์ได้จริงในอนาคต

ประโยชน์ของโครงการ

- 1.ช่วยให้สามารถ คัดการณ์ความเสี่ยงของโรคหัวใจได้ล่วงหน้า โดยอาศัยข้อมูลสุขภาพพื้นฐานของผู้ป่วย ทำให้สามารถตรวจพบภาวะผิดปกติได้ตั้งแต่ระยะเริ่มต้น
- 2.สนับสนุน การตัดสินใจของแพทย์และบุคลากรทางการแพทย์ ด้วยข้อมูลเชิงวิเคราะห์จากแบบจำลอง Machine Learning ที่ช่วยประเมินความเสี่ยงได้อย่างแม่นยำและเป็นระบบ
- 3.เพิ่มความเข้าใจเกี่ยวกับ กระบวนการทำงานของ Machine Learning ตั้งแต่การเก็บข้อมูล การเลือกคุณลักษณะ การสร้างและประเมินโมเดล ซึ่งสามารถนำความรู้ไปประยุกต์ใช้ในงานวิเคราะห์ข้อมูลด้านอื่นได้
- 4.เป็นแนวทางในการพัฒนา ระบบวิเคราะห์สุขภาพอัตโนมัติ (Health Prediction System) ที่สามารถนำไปต่อยอดเป็นเว็บแอปหรือแอปพลิเคชันสำหรับผู้ใช้งานทั่วไป
- 5.ช่วยส่งเสริมให้เห็นถึง ศักยภาพของเทคโนโลยี AI และ Data Science ในการยกระดับคุณภาพชีวิตและลดภาระของระบบสาธารณสุขในอนาคต

บทที่ 1

Data Collection & Preprocessing

1. Exploratory Data Analysis (EDA)

EDA Summary (Shape, Dtype, Unique)

Shape: 303 rows × 14 columns

Dtypes:
 age: float64
 sex: float64
 cp: float64
 trestbps: float64
 chol: float64
 fbs: float64
 restecg: float64
 thalach: float64
 exang: float64
 oldpeak: float64
 slope: float64
 ca: object
 thal: object
 target: int64

Unique values per column:

age: 41 unique
 sex: 2 unique
 cp: 4 unique
 trestbps: 50 unique
 chol: 152 unique
 fbs: 2 unique
 restecg: 3 unique
 thalach: 91 unique
 exang: 2 unique
 oldpeak: 40 unique
 slope: 3 unique
 ca: 5 unique
 thal: 4 unique
 target: 5 unique

ภาพที่ 1 (EDA)

จากภาพที่ 1 Attribute แต่ละตัวมีความหมายดังนี้ age อายุ , sex เพศ , cp อาการเจ็บหน้าอก , trestbps ความดันโลหิตขณะพัก , chol คอเลสเตอรอล , fbs ระดับน้ำตาลในเลือด , restecg คลื่นหัวใจขณะพัก , thalach ภาวะธาตุซีซีเมีย , exang เจ็บหน้าอกขณะออกกำลังกาย , oldpeak ผลจากการตรวจจากเครื่อง ECG , slope ค่าความชัน , ca จำนวนเส้นเลือดใหญ่ที่มีปัญหา , thal อัตราการเดินหัวใจสูงสุด , target ผลการวินิจฉัย

จะสังเกตเห็นว่า มี Shape = 303rows x 14 Column หมายถึง มีข้อมูลทั้งหมด 303 ตัวอย่าง และมี 14 ฟีเจอร์ แต่ละฟีเจอร์มี dtype ดังภาพ ซึ่งส่วนใหญ่เป็น float64 (ข้อมูลตัวเลขทศนิยมความแม่นยำสูง) และมี object เก็บ string ถัดไปจะเป็น Unique หรือ distinct value ค่าที่ไม่ซ้ำกัน ซึ่งส่วนใหญ่จะมี ฟีเจอร์ที่มีความเป็น unique สูงๆ เช่น chol,thalach

Class Distribution Table

Class (Number)	Class Name	Sample Count
0	No Heart Disease	164
1	Mild Heart Disease	55
2	Moderate Heart Disease	36
3	Severe Heart Disease	35
4	Very Severe Heart Disease	13

ใน Dataset UCLrvine มีทั้งหมด 5 Class แบ่งเป็น ไม่เสี่ยง , เสี่ยงต่ำ , เสี่ยงกลาง , เสี่ยงสูง , เสี่ยงสูงมาก ตามลำดับ และมี Sample ดังตาราง

1.1 Exploratory Data Analysis (EDA)

EDA คือกระบวนการสำรวจและวิเคราะห์ข้อมูลเบื้องต้น เพื่อเข้าใจโครงสร้าง รูปแบบ และคุณสมบัติของข้อมูล ก่อนนำไปสร้างโมเดลหรือวิเคราะห์ขั้นสูงต่อไป

1.1.1 เหตุผลที่ต้องใช้ Exploratory Data Analysis (EDA)

EDA จะช่วยให้เราเข้าใจข้อมูลอย่างละเอียด เช่น รูปแบบข้อมูล ค่าที่หายไป (missing values) หรือ outliers ตรวจสอบความสมบูรณ์และความถูกต้องของข้อมูล ค้นหาความสัมพันธ์ระหว่างตัวแปรต่าง ๆ วางแผนการทำ Data Cleaning, Feature Engineering และ Modeling ได้อย่างมีประสิทธิภาพลดความเสี่ยงของการใช้ข้อมูลผิดพลาดหรือมี bias ในโมเดล

1.2 Missing Value Handling (Imputation / Drop)

1.2.1 Missing Value

Missing Value คือ ค่าว่างหรือข้อมูลที่ขาดหายไป ใน dataset เช่น ช่องข้อมูลที่ไม่มีค่า (อาจเป็น NaN, null, หรือช่องว่าง)

1.2.2 เหตุผลที่ต้องจัดการ Missing Value

- ข้อมูลที่ขาดหายอาจทำให้การวิเคราะห์และการสร้างโมเดลผิดพลาด
- หลายอัลกอริทึมไม่สามารถทำงานกับข้อมูลที่มี Missing Value ได้ตรง
- ถ้าไม่จัดการ อาจเกิด bias หรือผลลัพธ์ไม่น่าเชื่อถือ
- การจัดการช่วยให้ข้อมูลสมบูรณ์และโมเดลทำงานได้ดีขึ้น

Column	Missing Values	Has Missing
age	0	No
sex	0	No
cp	0	No
trestbps	0	No
chol	0	No
fbs	0	No
restecg	0	No
thalach	0	No
exang	0	No
oldpeak	0	No
slope	0	No
ca	4	Yes
thal	2	Yes
target	0	No

ภาพที่ 2 (ตรวจสอบ Missing Value)

จากภาพที่ 2 โมเดล Missing Value รวม 6 ค่าใน dataset ก่อนจัดการ missing value โดยแบ่งเป็น Feature ca จำนวน 4 ค่า และ Feature thal จำนวน 2 ค่า

1.2.3 วิธีจัดการ Missing Value

1. ในฟีเจอร์ ca มีชนิดข้อมูลเป็น object ซึ่งจะถูกแปลงค่าให้เป็น numeric ก่อน จากนั้น เติมค่า median เพื่อให้ปลอดภัยจาก outlier และค่าสัมพันธ์กับความรุนแรงของโรค
2. ในฟีเจอร์ thal มีชนิดข้อมูลเป็น object เช่นกัน จึงต้องแปลงค่าเป็น numeric จากนั้นเติม mode หรือ unknown เพื่อข้อมูลจำแนกกลุ่มที่ชัดเจน เติมค่าที่พบบ่อยที่สุดจะเสถียรมากกว่า

Column	Missing Values	Status
age	0	Fixed
sex	0	Fixed
cp	0	Fixed
trestbps	0	Fixed
chol	0	Fixed
fbs	0	Fixed
restecg	0	Fixed
thalach	0	Fixed
exang	0	Fixed
oldpeak	0	Fixed
slope	0	Fixed
ca	0	Fixed
thal	0	Fixed
target	0	Fixed

ภาพที่ 3 (หลังจัดการ missing value)

จากภาพที่3 ที่ไม่ลบ Missing Value เพราะ ถ้าลบอาจส่งผลกับ Sample Balance ได้ และบวกกับ ข้อมูลสุขภาพ แต่ละ record สำคัญมาก เพราะการทำนายต้องแม่นยำที่สุด

1.3 Outlier Detection & Handling


1.3.1 Outlier (ค่าผิดปกติ) คือ ค่าข้อมูลที่แตกต่างหรือเบี่ยงเบนจากค่าทั่วไปอย่างชัดเจน เช่น อายุ = 250 ความดัน = 0 คอเลสเทอรอล = 9999 ค่าพวกนี้อาจเกิดจาก การพิมพ์ผิด (data entry error) , ความผิดพลาดในการวัด

1.3.2 เหตุผลที่ต้องจัดการ Outlier

1. ทำให้โมเดลเรียนรู้ผิดพลาด
 - โดยเฉพาะโมเดลที่อ่อนไหวต่อค่าผิดปกติ เช่น Linear Regression, KNN
 - อาจทำให้สมการหรือ decision boundary เบี่ยงเบน
2. ทำให้ค่าทางสถิติ (เช่น mean) บิดเบือน
 - ส่งผลต่อการเติม missing, normalization ฯลฯ
3. ลดความแม่นยำของโมเดล
 - โดยเฉพาะกรณีที่ outlier ไม่มีความหมายจริง (noise)

1.3.3 วิธีจัดการ Outlier

1. Boxplot
 - เป็นกราฟแสดงการกระจายของข้อมูล Outlier จะปรากฏเป็นจุดเด่นที่อยู่นอก “กล่อง” (ช่วง IQR)
 - ช่วยให้เห็นภาพรวมว่าค่าผิดปกติมีมากน้อยแค่ไหน
2. Z-score
 - เป็นค่าที่บอกว่าแต่ละจุดข้อมูลห่างจากค่าเฉลี่ยกี่เท่าของส่วนเบี่ยงเบนมาตรฐาน
 - ถ้า Z-score มากกว่า 3 หรือ น้อยกว่า -3 แปลว่าค่านั้นห่างจากค่าเฉลี่ยมาก ถือว่าเป็น outlier
3. IQR (Interquartile Range)
 - คือตัววัดการกระจายของข้อมูลในช่วงกลาง 50%
 - คำนวณจากช่วงระหว่าง Q1 (25%) และ Q3 (75%)
 - ค่าที่อยู่นอกช่วง $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ ถือว่าเป็น outlier
4. Winsorizing
 - เป็นวิธีจัดการ outlier โดย แทนค่าผิดปกติด้วยขอบเขตที่กำหนด
 - แทนค่าที่ต่ำเกินไปด้วยค่าขอบล่างของ IQR
 - แทนค่าที่สูงเกินไปด้วยค่าขอบบนของ IQR
 - ช่วยลดผลกระทบจาก outlier โดยไม่ต้องลบข้อมูลทิ้ง




ภาพที่ 4 (ก่อนจัดการ outlier)

จากภาพที่ 4 Boxplot ของทุกฟีเจอร์ตัวเลข (ยกเว้น target) เช่น age, trestbps, chol, thalach, oldpeak ด้านบนของแต่ละ box จะมีตัวเลขสีแดงเขียนว่า Outliers: X หมายถึงจำนวน outlier ที่ตรวจเจอในแต่ละฟีเจอร์ ตาม IQR method แกน X: ชื่อของฟีเจอร์ (เช่น age, chol, thalach) แกน Y: ค่าตัวเลขของฟีเจอร์นั้น ๆ เช่น ค่าความดัน, คอเลสเตอรอล, อัตราการเต้นของหัวใจ ฯลฯ

ตัวอย่างการแปลผลจากรูป

ถ้า chol (คอเลสเตอรอล) มี Outliers: 10

- หมายความว่า มี 10 record ที่ค่าคอเลสเตอรอล สูงเกินหรือ ต่ำเกินกว่าช่วงปกติ
- อาจต้องจัดการ เช่น winsorizing, scaling, หรือแม้แต่ตัดออก ถ้ามีผลมาก



ภาพที่ 5 (หลังจัดการ outlier)

จากภาพที่ 5 การโหลดข้อมูลและแปลงคอลัมน์ที่ไม่ใช่ตัวเลขให้เป็นตัวเลข เติมค่า missing จากนั้นหา outlier ด้วย 2 ดังนี้

Z-score: ค่าที่ห่างจากค่าเฉลี่ยมากกว่า 3 เท่าของส่วนเบี่ยงเบนมาตรฐาน , IQR: ค่าที่อยู่นอกช่วง $[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$

โดยจัดการ outlier ด้วย Winsorizing (จำกัดค่าสูง-ต่ำให้อยู่ในช่วงปกติ) แสดงกราฟ Boxplot พร้อมบอกจำนวน outlier ก่อนและหลังจัดการ เพื่อดูผลลัพธ์

1.4 Encode Categorical & Scale Numerical Features

ขั้นตอนนี้เป็น การแปลงข้อมูลให้โมเดลเข้าใจได้ง่ายและเหมาะสม เพราะโมเดล Machine Learning ส่วนใหญ่รับแค่ตัวเลข ไม่เข้าใจข้อความหรือค่าหมวดหมู่โดยตรง

1.4.1 Encode Categorical Features

Encode Categorical Features คือการแปลงข้อมูลประเภท หมวดหมู่ (categorical data) เช่น ca , thal ให้กลายเป็นตัวเลข เพื่อให้โมเดลสามารถนำไปใช้ได้

ตัวอย่างวิธี :

- Label Encoding: แปลงแต่ละหมวดหมู่เป็นเลข (0,1,2...)
- One-Hot Encoding: แปลงเป็นคอลัมน์ใหม่แยกแต่ละหมวดหมู่ เป็น 0 หรือ 1

1.4.2 Scale Numerical Features

Scale Numerical Feature คือการปรับขนาดข้อมูลตัวเลขให้มีสเกลหรือช่วงค่าใกล้เคียงกัน เพื่อช่วยให้โมเดลเรียนรู้ได้ดีขึ้นและเร็วขึ้น

ตัวอย่างวิธี :


- StandardScaler: ปรับข้อมูลให้มีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1
- 1MinMaxScaler: ปรับข้อมูลให้อยู่ในช่วง 0 ถึง 1

Dataset Before Encode

293	63.00	1.00	4.00	140.00	187.00	0.00	2.00	144.00	1.00	3.00	1.00	2.00	7.00	2.00
294	63.00	0.00	4.00	124.00	197.00	0.00	0.00	136.00	1.00	0.00	2.00	0.00	3.00	1.00
295	41.00	1.00	2.00	120.00	157.00	0.00	0.00	182.00	0.00	0.00	1.00	0.00	3.00	0.00
296	59.00	1.00	4.00	161.75	176.00	0.00	2.00	90.00	0.00	1.00	2.00	2.00	6.00	3.00
297	57.00	0.00	4.00	140.00	241.00	0.00	0.00	123.00	1.00	0.20	2.00	0.00	7.00	1.00
298	45.00	1.00	1.00	110.00	264.00	0.00	0.00	132.00	0.00	1.20	2.00	0.00	7.00	1.00
299	68.00	1.00	4.00	144.00	193.00	0.00	0.00	141.00	0.00	3.00	2.00	2.00	7.00	2.00
300	57.00	1.00	4.00	130.00	131.00	0.00	0.00	115.00	1.00	1.20	2.00	1.00	7.00	3.00
301	57.00	0.00	2.00	130.00	236.00	0.00	2.00	174.00	0.00	0.00	2.00	1.00	3.00	1.00
302	38.00	1.00	3.00	138.00	175.00	0.00	0.00	173.00	0.00	0.00	1.00	1.00	3.00	0.00
	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target

ภาพที่ 6 (ก่อนจัดการ encode)

จากภาพที่6 แถวแรกของข้อมูลดิบในตาราง (ก่อนการเตรียมข้อมูล) คอลัมน์แนวตั้ง คือ ทุกฟีเจอร์ใน dataset เช่น age, sex, cp, chol, thal แต่ละช่องในตาราง แสดงค่าของแต่ละ feature สำหรับแต่ละ record (แถว) สีของช่อง: สีเข้ม = ค่าสูง สีอ่อน = ค่าต่ำ ช่วยให้เห็นแนวโน้มของข้อมูลคร่าว ๆ มีค่าที่เป็นข้อความหรือ missing (?) บางจุด ซึ่งค่าพวกนี้จะไม่สามารนำไป train model ได้โดยตรง และเป็นเหตุผลที่ต้องทำการ encode / แปลงเป็นตัวเลขในขั้นถัดไป



ภาพที่ 7 (หลัง encode)

ได้มีการทำ Encoding เพื่อแปลงตัวแปรเชิงหมวดหมู่ (เช่น sex, cp, thal) เป็นตัวเลข และทำ Scaling ด้วย StandardScaler เพื่อปรับค่าข้อมูลให้อยู่ในมาตรฐานเดียวกัน (ค่าเฉลี่ย ≈ 0 และส่วนเบี่ยงเบนมาตรฐาน ≈ 1) ทำให้ข้อมูลทั้งหมดพร้อมสำหรับสร้างโมเดล จาก Heatmap พบว่าพื้นที่สีเข้มคือค่าที่สูงกว่าเฉลี่ย สีส่อนคือต่ำกว่าเฉลี่ย ช่วยให้เห็นการแปรผันของแต่ละ feature ได้ชัดเจน และไม่มี Missing Value เหลืออยู่เนื่องจากได้จัดการไว้แล้วด้วย median และ mode

1.5 Data Splitting (Train/Test หรือ Train/Validation/Test)

Data Splitting คือ การแบ่งชุดข้อมูลทั้งหมดออกเป็นหลายส่วน เพื่อใช้ในวัตถุประสงค์ต่างกัน เช่น

Training Set , Validation Set , Test Set

1.5.1 เหตุผลที่จะต้องแบ่งข้อมูล

ถ้าใช้ข้อมูลชุดเดียวกันทั้งเทรนและทดสอบโมเดลจะจำข้อมูลมากกว่าการเรียนรู้จริง จะเกิด Overfitting ดังนั้นเราต้องใช้ ข้อมูลที่โมเดลไม่เคยเห็นมาก่อน เพื่อทดสอบความแม่นยำ

1.5.2 รูปแบบที่เลือกใช้งาน

ข้อมูลทั้งหมดมีจำนวน 303 records หลังจากจัดการ missing และ outlier. ในขั้นตอนการสร้างโมเดล เราได้แบ่งข้อมูลออกเป็น training set 80% และ test set 20% ซึ่งทำให้ training set มีทั้งหมดจำนวน 242 records test set มีจำนวน 61 records

บทที่ 2

Feature Selection

2. Correlation Analysis

Correlation Analysis คือการวิเคราะห์ความสัมพันธ์เชิงเส้นระหว่างตัวแปร 2 ตัวขึ้นไป โดยจะบอกว่าตัวแปรสองตัวนั้นสัมพันธ์กันมากน้อยแค่ไหน และในทิศทางไหน เช่น

- ค่า Correlation coefficient (r) มีค่าอยู่ระหว่าง -1 ถึง 1
 - $r = 1$ หมายถึง ความสัมพันธ์เชิงบวกที่สมบูรณ์ (เพิ่มขึ้นพร้อมกัน)
 - $r = -1$ หมายถึง ความสัมพันธ์เชิงลบที่สมบูรณ์ (เพิ่มขึ้นในตัวแปรหนึ่ง ตัวแปรอื่นลดลง)
 - $r = 0$ หมายถึง ไม่มีความสัมพันธ์เชิงเส้น

2.1 เหตุผลที่ต้องทำ Correlation Analysis

2.1.1 เพื่อดูว่าฟีเจอร์แต่ละตัวสัมพันธ์กับ Target แบบใด


- ฟีเจอร์ที่มีความสัมพันธ์สูงกับ Target อาจมีความสำคัญในการทำนาย
- ฟีเจอร์ที่ไม่มีความสัมพันธ์เลย อาจไม่ช่วยเพิ่มประสิทธิภาพของโมเดล

2.1.2 เพื่อดูว่าฟีเจอร์แต่ละตัวสัมพันธ์กันแบบใด

- ฟีเจอร์ที่มีความสัมพันธ์สูงเกินไปกันเอง (multicollinearity) อาจทำให้โมเดลทำงานไม่ดี หรือ ซ้ำซ้อน
- อาจพิจารณาตัดฟีเจอร์ที่ซ้ำซ้อนออก (Feature Reduction)

2.1.3 วิธีใช้ใน Feature Selection

- เลือกฟีเจอร์ที่มี correlation สูงกับ Target (เชิงบวกหรือลบ)
- ตัดฟีเจอร์ที่มี correlation สูงกับกันเอง (สูงเกินกว่าค่าที่กำหนด เช่น > 0.8 หรือ < -0.8)
- ใช้ผลวิเคราะห์นี้ช่วยลดจำนวนฟีเจอร์ให้เหลือเฉพาะฟีเจอร์สำคัญ




ภาพที่ 8 (Correlation Heatmap)

สีและตัวเลขแสดงระดับความสัมพันธ์ระหว่างฟีเจอร์และกับตัวแปรเป้าหมาย (target) โดย สีแดงเข้ม หมายถึงความสัมพันธ์เชิงบวกสูง, สีฟ้าเข้ม หมายถึงความสัมพันธ์เชิงลบสูง และ สีขาว หมายถึงไม่มีความสัมพันธ์อย่างมีนัยสำคัญ ทั้งนี้ ฟีเจอร์ที่มีความสัมพันธ์สูงกับ target ถือเป็นฟีเจอร์สำคัญต่อโมเดล ส่วน ฟีเจอร์ที่มีความสัมพันธ์กันเองในระดับสูง อาจทำให้เกิดความซ้ำซ้อนของข้อมูล จึงควรพิจารณาลดจำนวนฟีเจอร์เพื่อเพิ่มประสิทธิภาพของโมเดล


Heatmap นี้ช่วยให้เราเห็นภาพรวมว่า ฟีเจอร์ไหนสำคัญ ที่มีผลต่อ target ช่วยตรวจสอบความสัมพันธ์ภายในข้อมูลว่า ฟีเจอร์ใดอาจซ้ำซ้อนหรือเกี่ยงข้องกันเกินไป เป็นจุดเริ่มต้นที่ดีสำหรับการเลือกฟีเจอร์ (feature selection) เพื่อพัฒนาโมเดลที่แม่นยำและง่ายต่อการตีความ

2.2 Model-based Feature Importance


เริ่มต้นจากการเทรนหลายๆ โมเดลจากนั้นเลือก Feature ที่ดีที่สุด จากโมเดลที่ดีที่สุดจากภาพ 3 ภาพดังกล่าว



ภาพที่ 9 (Random Forest)



ภาพที่ 10 (XGBoost)



ภาพที่ 11 (Logistic Regression)

จะสังเกตว่า ในส่วนของ XGBoost Model มี Feature CP ที่โดดเด่นอย่างชัดเจน หมายความว่า มีเพียงแค่ CP ที่เป็นส่วนสำคัญของการตัดสินใจของโมเดล , ส่วนทางด้านของ Logistic Regression สมมติความสัมพันธ์เชิงเส้นระหว่างฟีเจอร์กับผลลัพธ์ ซึ่งอาจจำกัดในกรณีที่ข้อมูลมีความซับซ้อน แล้วมี Feature โดดออกมาเด่นๆ 2 Feature คือ ca,sex แต่ในส่วนของ Random Forest มีทุกฟีเจอร์ที่น้ำหนักการตัดสินใจ แบบรวมกันสำคัญกว่า

2.2.1 เหตุผลที่ควรเลือก Random Forest ใน Feature Selection

2.2.1.1 ความเสถียรและความน่าเชื่อถือสูงกว่าโมเดลเดี่ยว

RF เป็นการรวมหลายต้นไม้ (ensemble) ทำให้ผลลัพธ์ไม่ขึ้นกับตัวอย่างเดียวหรือฟีเจอร์เดียวมากเกินไป ลดความลำเอียง (bias) และความผันผวน (variance) ของ feature importance

2.2.1.2 จับความสัมพันธ์เชิงซ้อนระหว่างฟีเจอร์ได้ดี

RF สามารถจับ interaction (ปฏิสัมพันธ์) ระหว่างฟีเจอร์หลายตัวได้มากกว่า LR หรือ XGBoost บางครั้ง ซึ่งช่วยให้การประเมินความสำคัญของฟีเจอร์แม่นยำกว่า

2.2.1.3 ไม่มีสมมติฐานเชิงเส้น (non-parametric)

Logistic Regression สมมติความสัมพันธ์เชิงเส้นระหว่างฟีเจอร์กับผลลัพธ์ ซึ่งอาจจำกัดในกรณีที่ข้อมูลมีความซับซ้อน RF ไม่มีสมมติฐานนี้ จึงยืดหยุ่นกว่ามาก


2.2.1.4 ให้ภาพรวมของฟีเจอร์ที่ใช้งานได้ครบถ้วน

RF ไม่มีฟีเจอร์ใดเด่นมากเกินไป แสดงว่าฟีเจอร์หลายตัวมีบทบาทร่วมกัน ทำให้ได้มุมมอง holistic มากกว่า เหมาะกับกรณีที่ต้องการรักษาฟีเจอร์หลายตัวที่ช่วยให้โมเดลทำงานดี

2.3 Explainability Methods (SHAP, Mutual Information (MI))

2.3.1 SHAP (Shapley additive explanations)

SHAP (Shapley additive explanations) เป็นเทคนิคที่ใช้ในการอธิบายผลลัพธ์ของโมเดล Machine Learning อย่างละเอียด โดยวิเคราะห์ว่าฟีเจอร์แต่ละตัวมีผลต่อการทำนายของโมเดลอย่างไร โดยอิงจากแนวคิด Shapley values ในทฤษฎีเกมที่แจกแจงความรับผิดชอบของแต่ละตัวแปรต่อผลลัพธ์ ทำให้สามารถระบุได้ว่าฟีเจอร์ไหนช่วยเพิ่มหรือลดค่าการทำนายในแต่ละตัวอย่าง อีกทั้งยังช่วยให้เห็นภาพรวมฟีเจอร์สำคัญของโมเดล ซึ่งช่วยในการเลือกฟีเจอร์ที่มีอิทธิพลสูงหรือตัดฟีเจอร์ที่แทบไม่มีผล SHAP จึงทำให้เราเข้าใจว่าโมเดลคิดอย่างไรกับฟีเจอร์ต่าง ๆ เพิ่มความน่าเชื่อถือของโมเดลมากขึ้น



ภาพที่12 (SHAP)

แกน y = ฟีเจอร์ต่าง ๆ (เรียงตามความสำคัญ) แกน x = ผลกระทบของฟีเจอร์นั้น ๆ ต่อตัวแปรเป้าหมาย (ค่าบวก = เพิ่มโอกาส, ค่าลบ = ลดโอกาส) จุดแต่ละจุด = ตัวอย่างข้อมูล 1 ตัว สีจุด = ค่าฟีเจอร์ (แดง = สูง, น้ำเงิน = ต่ำ) ฟีเจอร์บนสุด = สำคัญที่สุด จุดแดงถ้าอยู่ขวาค่ายิ่งสูงยิ่งเพิ่มผลลัพธ์, จุดแดงถ้าอยู่ซ้ายค่ายิ่งสูง ยิ่งลดผลลัพธ์, สีสลับกันผลลัพธ์ซับซ้อนหรือไม่มีทิศทางชัดเจน


2.3.2 Mutual Information (MI)

Mutual Information (MI) ใช้วัดความสัมพันธ์ระหว่างสองตัวแปร โดยไม่จำเป็นต้องเป็นเชิงเส้น

หลักการ วัดว่าการรู้ค่าของฟีเจอร์หนึ่งช่วยลดความไม่แน่นอน (entropy) ของตัวแปรเป้าหมาย (target) ได้มากแค่ไหนค่า MI สูง แปลว่าฟีเจอร์นั้นมีข้อมูลที่เกี่ยวข้องกับ target มาก

ประโยชน์ : ใช้เพื่อเลือกฟีเจอร์ที่เกี่ยวข้องกับ target จริงที่เหมาะสมกับข้อมูลที่มีความสัมพันธ์แบบซับซ้อนหรือไม่เป็นเชิงเส้น

สรุป : SHAP ช่วยทำให้เรา รู้ว่าโมเดลคิดอย่างไร กับฟีเจอร์ต่าง ๆ ช่วยเพิ่มความโปร่งใสและความน่าเชื่อถือของโมเดล



ภาพที่ 13 (Mutual Information)

วิธีการวิเคราะห์ Mutual Information (MI) ใช้เพื่อวัดระดับความสัมพันธ์ระหว่างฟีเจอร์กับตัวแปรเป้าหมาย โดย ค่าของ MI ที่สูง แสดงว่าฟีเจอร์นั้นมีข้อมูลที่ช่วยในการทำนายมากและมีความสำคัญต่อโมเดล ในทางตรงกันข้าม ค่า $MI = 0$ หมายถึงฟีเจอร์นั้นไม่มีความสัมพันธ์กับเป้าหมายเลย การเปรียบเทียบค่า MI ของฟีเจอร์หลายตัวช่วยให้สามารถคัดเลือกเฉพาะฟีเจอร์ที่มีค่า MI สูง เพื่อนำไปใช้สร้างโมเดลได้อย่างมีประสิทธิภาพ ยิ่งค่า MI สูง ฟีเจอร์นั้นยังมีความสำคัญต่อการพยากรณ์

2.4 Feature Pruning

Feature Pruning คือกระบวนการ ตัดหรือลดจำนวนฟีเจอร์ (ตัวแปร) ในชุดข้อมูลให้น้อยลง โดยลบฟีเจอร์ที่

- ไม่สำคัญหรือไม่ช่วยให้โมเดลทำงานดีขึ้น
- ซ้ำซ้อนหรือมีความสัมพันธ์สูงกับฟีเจอร์อื่น (multicollinearity)
- มีข้อมูลไม่ดีหรือมี noise สูง

ประโยชน์ของ Feature Pruning คือช่วยลดความซับซ้อนของโมเดล ทำให้โมเดลเรียนรู้เร็วขึ้น ลดโอกาส overfitting และทำให้โมเดลตีความง่ายขึ้น

2.4.1 Sequential Forward Selection (SFS)

- เริ่มจากไม่มีฟีเจอร์เลย (empty set)
 - เพิ่มฟีเจอร์ที่ช่วยให้โมเดลดีขึ้นมากที่สุดทีละตัว
 - ทำซ้ำจนกว่าจะได้จำนวนฟีเจอร์ที่ต้องการ หรือโมเดลไม่ดีขึ้นอีก
- ผลลัพธ์คือชุดฟีเจอร์ที่ "ดีที่สุด" ที่ถูกคัดเลือกขึ้นมาแบบทีละขั้น (greedy approach)

2.4.2 Sequential Backward Selection (SBS)

- เริ่มจากฟีเจอร์ทั้งหมดในชุดข้อมูล
- ลบฟีเจอร์ที่ส่งผลกระทบต่อประสิทธิภาพโมเดลน้อยที่สุดทีละตัว
- ทำซ้ำจนกว่าจะได้จำนวนฟีเจอร์ที่ต้องการ หรือโมเดลแย่ลงมาก
- ผลลัพธ์คือชุดฟีเจอร์ที่ถูกตัดทอนออกอย่างเป็นระบบ

โดยคณะผู้จัดทำได้ทำการทำทั้ง SFS และ SBS เพื่อคัดเลือกฟีเจอร์ ผลลัพธ์ออกมาดังนี้



ภาพที่ 14 (SFS VS SBS Accuracy)

โดยได้ผลลัพธ์ SFS selected features (9): ('sex', 'cp', 'fbs', 'restecg', 'thalach', 'exang', 'oldpeak', 'ca', 'thal')


SBS selected features (8): ('cp', 'trestbps', 'chol', 'thalach', 'exang', 'oldpeak', 'ca', 'thal') จะสังเกตเห็นว่าเส้นสีส้มหรือ

Sequential Backward Search มี Accuracy โดยรวมที่สูงกว่า และมีฟีเจอร์ดังกล่าว แต่ต้องการโมเดลที่ใช้งานได้จริง จึงทำการ ใช้ชุด ฟีเจอร์จาก SBS โดยเพิ่มฟีเจอร์ sex, age เข้าไปเสริม


บทที่ 3

Modeling


3.1 การฝึกโมเดลการพยากรณ์ (Train Models เช่น Logistic Regression, RF, XGBoost, LSVM)



ภาพที่ 15 (Confusion Matrix RF)



ภาพที่ 16 (Confusion Matrix XGB)



ภาพที่ 17 (Confusion Matrix LR)

จากภาพจะเห็นอย่างชัดเจนว่า ทั้ง 3 โมเดล เห็นชัดเจนว่า Random Forest มีค่าความแม่นยำที่สูงที่สุด จากการ ทาย TN ในค่า 0 ถูกถึง 32 ครั้งแล้วมีค่าที่ผิดน้อยกว่าโมเดลอื่นๆอย่างชัดเจน แต่ไม่สามารถทาย Class ที่นอกเหนือจากนั้นได้เลยจึงต้องมีการปรับแก้ไข

3.2 Model Validation & Bias-Variance Check

3.2.1 Model Validation

Model Validation คือการทดสอบว่าโมเดลที่เราสร้างขึ้นสามารถทำงานได้ดีแค่ไหนกับข้อมูลที่มันไม่เคยเห็นมาก่อน เช่น การใช้ชุดข้อมูล validation หรือ test เพื่อดูว่าความแม่นยำของโมเดลเป็นอย่างไรจริง ๆ ไม่ใช่แค่กับข้อมูลที่ใช้เทรน


3.2.2 Bias-Variance Check

Bias-Variance Check คือการตรวจสอบว่าโมเดลของเรามีปัญหาแบบไหนโดยแบ่งประเภทดังนี้

- **Bias สูง (underfitting)** โมเดลเรียนรู้ข้อมูลไม่ดีพอ ทำให้แม้แต่กับข้อมูลเทรนก็ยังทำนายไม่แม่นยำ (ความแม่นยำต่ำทั้ง train และ validation)
- **Variance สูง (overfitting)** โมเดลเรียนรู้ข้อมูลเทรนละเอียดเกินไป จนทำงานไม่ดีเมื่อเจอข้อมูลใหม่ (train แม่นยำมากแต่ validation ต่ำ)

เรามักใช้ Learning Curve มาช่วยดูเรื่องนี้ โดย plot ความแม่นยำ (หรือ error) ของ train และ validation ตามขนาดข้อมูลที่ใช้เทรน

- ถ้า train กับ val score ต่ำทั้งคู่ = โมเดล underfit (bias สูง)
- ถ้า train score สูง แต่ val score ต่ำ = โมเดล overfit (variance สูง)
- ถ้า train กับ val score ใกล้เคียงและสูง = โมเดลสมดุลดี



ภาพที่ 18 (Learning Curve RF)

Training Score อยู่ในระดับสูงมาก แต่มี Value Score ต่ำมาก ซึ่งตีความได้ว่า โมเดล Overfitting สูง Variance สูง จำเป็นจะต้องทำขั้นตอน Handling


3.3 Hyperparameter Tuning (GridSearchCV, Random Search)

ได้ทดลองใช้ GridSearchCV เพื่อปรับค่าพารามิเตอร์ของ Random Forest เช่น max_depth, min_samples_leaf, n_estimators โดยใช้ accuracy และ f1_macro เป็นเกณฑ์วัดผล แต่พบว่าโมเดลที่ได้จาก GridSearchCV มีประสิทธิภาพต่ำกว่าการปรับค่าด้วยตนเอง สาเหตุคือข้อมูลมีขนาดเล็กและไม่สมดุล ทำให้โมเดลที่เลือกจาก cross-validation มักมีลักษณะ conservative เกินไป ส่งผลให้จับคลาสน้อย (เช่น target = 3, 4) ได้น้อย

3.4 Cross-validation (K-Fold CV)

ได้ทดลองใช้ K-Fold Cross-validation เพื่อวัด performance ของโมเดล แต่พบว่าผลคะแนนในแต่ละ fold มีความแปรปรวนสูง เนื่องจากจำนวนข้อมูลต่อคลาสนี้น้อย และไม่สมดุล โดยเฉพาะเมื่อแบ่ง fold แล้วทำให้บางคลาสนี้อาจมีข้อมูลไม่ครบ หรือมีจำนวนน้อยเกินไป ทำให้โมเดลไม่สามารถเรียนรู้ได้อย่างเหมาะสม

จึงเลือกใช้วิธี manual tuning และประเมินด้วย confusion matrix, learning curve และ classification report แทน



ภาพที่ 19 (Learning Curve)

Learning curve แสดงว่าโมเดลเริ่มมี performance คงที่เมื่อขนาดข้อมูลเพิ่มขึ้น แต่ยังคงมีความแตกต่างระหว่าง training และ validation เล็กน้อย แสดงว่าอาจยังมี bias หรือข้อมูลไม่ครอบคลุมบางคลาสนี้อย่างเพียงพอ เช่น คลาสที่ 4

บทที่ 4

Evaluation Metrics

4.1 Evaluate Performance

โมเดล Random Forest ถูกเทรนด้วยข้อมูลที่ผ่านการปรับสมดุลด้วย Hyper Tuning แล้วสามารถเรียนรู้ข้อมูลในชุดเทรนได้ดี อย่างไรก็ตาม ผลการทดสอบบนข้อมูลจริง (validation/test set) มี accuracy เพียง 47.54% ซึ่งแสดงให้เห็นว่าโมเดลมีแนวโน้ม overfitting ซึ่งหมายถึง โมเดลเรียนรู้ข้อมูลเทรนได้ดีเกินไปจนไม่สามารถ generalize ไปยังข้อมูลใหม่ได้อย่างแม่นยำจากตารางเราสามารถสังเกตได้ว่า

Class	Precision	Recall	F1-score	Support
0	0.88	0.70	0.78	33
1	0.25	0.27	0.26	11
2	0.12	0.14	0.13	7
3	0.18	0.29	0.22	7
4	0.00	0.00	0.00	3
Accuracy			0.4754	61
Macro Avg	0.29	0.28	0.28	61
Weighted Avg	0.56	0.48	0.51	61

- คลาส 0 (กลุ่มใหญ่สุด) มี precision และ recall สูงมาก แสดงว่าโมเดลสามารถจำแนกคลาสนี้ได้ดี
- คลาส 1-3 มี precision และ recall ต่ำมาก โดยเฉพาะคลาส 2 และ 3 ที่มี f1-score ต่ำกว่า 0.25
- คลาส 4 ซึ่งมีจำนวนน้อยที่สุด (3 ตัวอย่างใน test set) โมเดลไม่สามารถทำนายได้เลย
- ค่า macro avg f1-score = 0.28 = สะท้อนว่า performance ทั้งทั้งคลาสโดยเฉลี่ยยังต่ำ
- ค่า weighted avg f1-score = 0.51 = โอเคขึ้นเพราะคลาส 0 ถ่วงน้ำหนักอยู่มาก

ซึ่งคณะผู้จัดทำได้ลองใช้ Hyper parameter tuning แล้วแต่ test performance ยังไม่ดีขึ้น จึงสรุปว่าเป็นข้อจำกัดของ dataset ด้วยเหตุนี้จึงได้แก้ปัญหาโดยการรวม Class 1-2 เข้าด้วยกัน เป็น Class 1 และ Class 3-4 เข้าด้วยกันเป็น Class 2 ด้วยเหตุผลดังนี้

4.1.1 การวิเคราะห์ปัญหาความไม่สมดุลของข้อมูล

- Class 2 มีแค่ 7 ตัวอย่างจากทั้งหมด 61 = เทรนไม่ได้ผล
- Class 3 มีแค่ 7 ตัวอย่างจากทั้งหมด 61 = เทรนไม่ได้ผล
- Class 4 มีแค่ 3 ตัวอย่างจากทั้งหมด 61 = เทรนไม่ได้ผล


4.1.2 การประเมินประสิทธิภาพของโมเดลเมื่อไม่สามารถทำนายคลาส 4

- precision/recall = 0 = ไม่มีประโยชน์ในการทำนาย

4.1.3 การวิเคราะห์เบื้องต้น

นอกจากการวิเคราะห์เบื้องต้นแล้วพบว่า class 1 กับ 2 และ class 3 กับ 4 มีลักษณะ feature ใกล้เคียงกัน เช่น

- thal defect, oldpeak สูง, thalach ต่ำ
รวมเป็น กลุ่มเสี่ยงปานกลาง และ กลุ่มเสี่ยงสูง ให้โมเดลเข้าใจง่ายขึ้น



ภาพที่ 20 (Confusion matrix หลังรวม Class 1-2 , 3-4 ใน RF)

Class	Precision	Recall	F1-score	Support
0	0.8378	0.9394	0.8857	33
1	0.5789	0.6111	0.5946	18
2	0.4000	0.2000	0.2667	10
Accuracy			0.7213	61
Macro Avg	0.6056	0.5835	0.5823	61
Weighted Avg	0.6897	0.7213	0.6983	61

4.2 Export Model (pickle, joblib)

หลังจากทำการเทรนโมเดล Random Forest ด้วยข้อมูล train set และประเมินผลกับ test set เรียบร้อยแล้ว เราได้ทำการบันทึกโมเดลที่ผ่านการเทรนแล้วไว้ในไฟล์ rf_model.pkl ด้วยไลบรารี joblib เพื่อให้นำโมเดลนี้ไปใช้ในขั้นตอน deployment หรือนำไปใช้งานต่อในอนาคตโดยไม่ต้องเทรนใหม่ทุกครั้ง

บทที่ 5

Explainability

5.1 ชี้แจงว่าฟีเจอร์ไหนมีผลต่อการพยากรณ์

ได้ทำการวิเคราะห์ Feature Importance จากโมเดล Random Forest เพื่อระบุฟีเจอร์ที่มีอิทธิพลต่อผลการพยากรณ์ โดยฟีเจอร์ที่มีค่าความสำคัญสูงจะส่งผลอย่างมากต่อการตัดสินใจของโมเดล ทั้งนี้ได้พิจารณาทิศทางของผลกระทบว่ามีแนวโน้มเชิงบวกหรือลบต่อคลาสเป้าหมาย ดังตารางต่อไปนี้

ฟีเจอร์	ทิศทางผล	คำอธิบาย
thal	บวก	ความผิดปกติของธาลัสซีเมีย (thalassemia) เพิ่มความเสี่ยงโรคหัวใจ
cp	บวก	ชนิดของอาการเจ็บหน้าอกแบบเฉพา (typical angina) เพิ่มความเสี่ยง
ca	บวก	จำนวนหลอดเลือดหัวใจที่มีปัญหา เพิ่มความรุนแรงของโรค
oldpeak	บวก	ST depression จากการออกกำลังกาย เชื่อว่าหัวใจมีปัญหา
thalach	ลบ	อัตราการเต้นหัวใจสูงสุดที่ได้ ยิ่งสูงยิ่งลดความเสี่ยงโรค
exang	บวก	การมีอาการเจ็บหน้าอกจากการออกกำลังกาย เพิ่มความเสี่ยง
chol	บวก	คอเลสเตอรอลสูง เพิ่มความเสี่ยงโรคหัวใจ
trestbps	บวก	ความดันโลหิตขณะพักสูง เพิ่มความเสี่ยงโรคหัวใจ

บทที่ 6

Deployment

6.1 สร้าง Web App ด้วย Streamlit

เราได้พัฒนาแอปพลิเคชันเว็บโดยใช้ Streamlit ซึ่งผู้ใช้งานสามารถกรอกข้อมูลฟีเจอร์ต่าง ๆ เช่น อายุ, ความดันโลหิต, ค่าคอเลสเตอรอล และอื่น ๆ จากนั้นระบบจะประมวลผลและแสดงผลลัพธ์การพยากรณ์ความเสี่ยงโรคหัวใจแบบเรียลไทม์ ทำให้ผู้ใช้งานเข้าถึงโมเดลได้ง่ายและสะดวก

โดยมีส่วนประกอบดังนี้คือ

1. Panel ด้านซ้ายเป็นแบบฟอร์มไว้สำหรับ กรอกข้อมูล โดย มี ทั้งหมด 10 Fill Form ใช้การเรียงลำดับตาม Feature Importance
2. Panel ด้านขวาเป็นข้อมูล ประกอบไว้สำหรับกรอกข้อมูลได้อย่างถูกต้อง มีการอธิบายเพิ่มเติมเกี่ยวกับ Class ต่างๆ

6.2 คำเตือนและข้อจำกัด

เพื่อความชัดเจนและความปลอดภัยของผู้ใช้ แอปพลิเคชันมีข้อความเตือนว่า:"เครื่องมือช่วยตัดสินใจเท่านั้น ไม่ใช่การวินิจฉัยแทนแพทย์ กรุณาปรึกษาแพทย์สำหรับการวินิจฉัยและรักษา"